

Challenge FIAP 2025

Sprint 4 – Análise de Consumo por Unidade e Material

Nimbly

Equipe: Nimbly

Fabício – RM 558216

Guilherme – RM 554962

Pedro – RM 555556

Vitor – RM 554893

Matheus – RM 555447

Sumário

Nimbly	1
Sumário	2
1. Objetivo	3
2. Fonte e estrutura dos dados	3
Colunas principais:	3
3. Limpeza e pré-processamento	3
4. Definição do target (binário)	3
5. Estatísticas descritivas (resumo selecionado)	4
Exemplo de algumas linhas agregadas (apresentadas no notebook):	4
6. Preparação de features e divisão de dados	4
7. Modelagem e métricas (resumo)	4
Classificação (target ATRASO_ENTREGA):	4
Modelos treinados e comparados:	4
Métricas no conjunto de teste:	4
Regressão Logística (interpretável, solver liblinear)	5
Métricas no conjunto de teste:	5
Principais features por Odds Ratio (top 10 ordenado):	5
Decision Tree (max_depth=5) e RandomForest (n_estimators=100, max_depth=5)	5
Regressão (prever CONSUMO_REAL):	6
Modelos testados e R^2 (no conjunto de teste):	6
8. Principais interpretações e recomendações	6
Interpretações:	6
Recomendações imediatas:	6
9. Limitações	7
Apêndice — Métricas detalhadas	7
Classificação:	7
Regressão:	7
Importância das features (Logistic Regression — OddsRatio):	7
Reprodutibilidade	7

1. Objetivo

O objetivo desta análise foi agrupar transações de consumo por par (unidade, material), extrair métricas agregadas e construir modelos para:

- Classificar pares (unidade, material) com maior risco de "atraso/criticidade" de entrega (target binário ATRASO_ENTREGA).
- Tentar prever o consumo real (CONSUMO_REAL) por par (regressão).

O insight buscado é priorizar ações operacionais e logísticas nas unidades/materiais de maior consumo ou risco.

2. Fonte e estrutura dos dados

Arquivo analisado: dados_consumo_simulados.csv

Colunas principais:

- data: data da transação
- unidade: local/filial (ex.: Moema, Santo Amaro, Morumbi)
- material: tipo de material (ex.: Tubo, Seringa, Medicamentos, Gaze, Esparadrapo)
- tipo: entrada/saida
- quantidade: valor numérico (saídas são negativas; entradas positivas)
- responsavel: usuário/operador da transação (valores vazios foram preenchidos como "desconhecido")

Registro total carregado durante a análise: 1100 linhas e 6 colunas.

3. Limpeza e pré-processamento

- Preenchimento de valores faltantes em `responsavel` com "desconhecido".
- Foi criada a variável `quantidade\_abs` = $\text{abs}(\text{quantidade})$ para medir volume de transação em valor absoluto (consumo).
- Agrupamento por (`unidade`, `material`) para gerar agregados por par:
- CONSUMO_REAL = soma de quantidade_abs por par
- qtd_transacoes = contagem de transações por par
- media_transacao = média de quantidade_abs por transação por par

4. Definição do target (binário)

- Target ATRASO_ENTREGA definido como 1 quando CONSUMO_REAL está no top 25% (maiores consumos) entre os pares; caso contrário 0.
- Limite do 75º percentil para CONSUMO_REAL observado: 2304.53
- Pares com CONSUMO_REAL > 2304.53 → ATRASO_ENTREGA = 1

5. Estatísticas descritivas (resumo selecionado)

Exemplo de algumas linhas agregadas (apresentadas no notebook):

- Moema / Tubo: CONSUMO_REAL = 2795.42, qtd_transacoes = 70, media_transacao $\approx$ 39.93 → ATRASO_ENTREGA = 1
- Moema / Medicamentos: CONSUMO_REAL = 1118.36, qtd_transacoes = 90, media_transacao $\approx$ 12.43 → ATRASO_ENTREGA = 0
- Moema / Gaze: CONSUMO_REAL = 913.45, qtd_transacoes = 70, media_transacao $\approx$ 13.05 → ATRASO_ENTREGA = 0
- Moema / Esparrapado: CONSUMO_REAL = 617.48, qtd_transacoes = 70, media_transacao $\approx$ 8.82 → ATRASO_ENTREGA = 0

Observação: alguns pares apresentam CONSUMO_REAL muito maior que a maioria — potenciais outliers ou casos com muitas entradas de entrada/saída agregadas.

6. Preparação de features e divisão de dados

- Features numéricas: qtd_transacoes, media_transacao (padronizadas com StandardScaler).
- Features categóricas: unidade, material (OneHotEncoding).
- Divisão treino/teste: 70% treino, 30% teste.
- Em classificação, tentativa de stratify com y_class; fallback para divisão sem estratificação se necessário.

7. Modelagem e métricas (resumo)

Classificação (target ATRASO_ENTREGA):

Modelos treinados e comparados:

- K-Nearest Neighbors (KNN) com seleção de K via cross-validation (cv ajustado de acordo com menor contagem de classe).
- K escolhido no experimento: 1

Métricas no conjunto de teste:

- Acurácia: 0.8
- Precisão: 0.0
- Recall: 0.0
- F1: 0.0
- Matriz de confusão (rótulos: [0,1]):
[[4 0]
[1 0]]

Observação: métricas de precisão/recall/F1 iguais a zero indicam que o modelo KNN não previu a classe positiva (ATRASO_ENTREGA=1) no conjunto de teste; possivelmente classes desequilibradas ou amostra de teste pequena.

Regressão Logística (interpretável, solver liblinear)

Métricas no conjunto de teste:

- Acurácia: 0.8
- Precisão: 0.5
- Recall: 1.0
- F1: 0.6667

As **métricas** indicam que o classificador de regressão logística conseguiu identificar todas as amostras positivas no teste (recall=1.0), com precisão moderada (0.5).

Principais features por Odds Ratio (top 10 ordenado):

- media_transacao — Coef: 1.0906 — OddsRatio $\approx$ 2.976
- material_Tubo — Coef: 0.4083 — OddsRatio $\approx$ 1.504
- qtd_transacoes — Coef: 0.1414 — OddsRatio $\approx$ 1.152
- material_Seringa — Coef: 0.1094 — OddsRatio $\approx$ 1.116
- unidade_Morumbi — Coef: 0.0145 — OddsRatio $\approx$ 1.015
- unidade_Moema — Coef: -0.1121 — OddsRatio $\approx$ 0.894
- material_Medicamentos — Coef: -0.1320 — OddsRatio $\approx$ 0.876
- material_Esparadrapo — Coef: -0.2593 — OddsRatio $\approx$ 0.772

- unidade_Santo Amaro — Coef: -0.3857 — OddsRatio $\approx$ 0.680
- material_Gaze — Coef: -0.6097 — OddsRatio $\approx$ 0.544

Interpretação breve: maior média por transação (`media_transacao`) e materiais como "Tubo" aumentam a probabilidade de o par ser classificado como de alto consumo/risco. Já materiais como "Gaze" ou unidades como "Santo Amaro" mostraram OddsRatio < 1 , associadas a menor probabilidade do target 1.

Decision Tree (`max_depth=5`) e RandomForest (`n_estimators=100`, `max_depth=5`)

- Ambas apresentaram (no teste):
- Acurácia: 0.8
- F1: 0.666667

Resultados muito próximos aos da regressão logística para este conjunto e partição de dados.

Regressão (prever `CONSUMO_REAL`):

Modelos testados e R^2 (no conjunto de teste):

- LinearRegression: $R^2 = -3.2587$ (muito ruim — modelo pior que a média)
- Ridge ($\alpha=1$): $R^2 = -0.3505$ (ainda ruim, mas melhor)
- Lasso ($\alpha=1$): $R^2 = -2.2719$
- PolynomialFeatures grau 2 + LinearRegression: $R^2 = 0.2101$ (melhor desempenho; consegue explicar $\sim 21\%$ da variância)

Observação: modelagem de regressão sofreu com dispersão e possíveis outliers (valores extremos de `CONSUMO_REAL`), tornando modelos lineares simples inadequados. Um modelo polinomial teve ganho, mas R^2 ainda moderado.

8. Principais interpretações e recomendações

Interpretações:

- A média por transação (`media_transacao`) é o preditor mais importante para identificar pares com alto consumo (`ATRASO_ENTREGA=1`). Isso sugere que pares com poucas transações, porém de grande volume médio, tendem a concentrar consumo e, portanto, risco.
- O material "Tubo" foi identificado como positivamente associado ao risco/alto consumo (OddsRatio ≈ 1.5).
- Alguns pares com `CONSUMO_REAL` muito alto (ex.: Moema/Tubo = 2795.42) puxam percentis e podem indicar consumos legítimos por alta demanda ou artefatos/outliers em lançamentos de entrada/saída. É necessária investigação por par para confirmar.

Recomendações imediatas:

1. Priorizar verificação operacional dos pares classificados com `ATRASO_ENTREGA = 1` (lista gerada no dataset agregado) — revisar histórico de entradas (recebimentos) e saídas para confirmar consumo real e possíveis erros de lançamento.
2. Implementar alertas operacionais baseados em média por transação (`media_transacao`) + limites adaptativos por material/unidade.
3. Reavaliar definição do target se o negócio preferir usar thresholds absolutos (ex.: valor monetário) ou métricas de cobertura de estoque, em vez de percentis absolutos.
4. Para previsão de `CONSUMO_REAL`, considerar:
 - Transformações robustas (log, winsorize) para mitigar outliers antes de ajustar regressões.
 - Modelos robustos (Gradient Boosting, XGBoost/LightGBM) e validação cruzada apropriada.
 - Incluir features temporais (sazonalidade, mês, semana) e informações de estoque/lead time do fornecedor se estiverem disponíveis.

9. Limitações

- Tamanho do conjunto agregado (número de pares) pode ser pequeno; amostras de teste podem conter muito poucas observações da classe positiva, afetando estabilidade das métricas.
- Uso de `CONSUMO_REAL` absoluto (somatório) sem normalização por capacidade/consumo esperado por material/unidade pode deixar fora do contexto operacional.
- Dados contêm entradas grandes (ex.: recebimentos) que elevam a variância; modelagem de regressão sensível a outliers.
- Não foram incluídos aspectos temporais (séries temporais) — a agregação por par perde informações de tendência e sazonalidade.

Apêndice — Métricas detalhadas

Classificação:

- KNN (k=1): Acurácia 0.8, Precisão 0.0, Recall 0.0, F1 0.0. Matriz de confusão: $\begin{bmatrix} 4 & 0 \\ 1 & 0 \end{bmatrix}$.
- Regressão Logística: Acurácia 0.8, Precisão 0.5, Recall 1.0, F1 0.6667.
- DecisionTree e RandomForest: Acurácia 0.8, F1 0.666667.

Regressão:

- Linear: $R^2 = -3.2587$
- Ridge: $R^2 = -0.3505$
- Lasso: $R^2 = -2.2719$
- Polynomial degree 2: $R^2 = 0.2101$

Importância das features (Logistic Regression — OddsRatio):

- media_transacao: OR $\approx$ 2.976
- material_Tubo: OR $\approx$ 1.504
- qtd_transacoes: OR $\approx$ 1.152
- material_Seringa: OR $\approx$ 1.116
- material_Gaze: OR $\approx$ 0.544
- unidade_Santo Amaro: OR $\approx$ 0.680
- unidade_Moema: OR $\approx$ 0.894

Reprodutibilidade

Todos os passos e resultados acima foram produzidos a partir do notebook `main.ipynb` que processa o arquivo `dados\_consumo\_simulados.csv`.